

面向多标签眼科疾病识别的可解释与隐私保护 单域泛化

摘要

早期眼底筛查是眼科疾病诊断有效方法。围绕眼底筛查，传统机器学习、视觉语言模型和卷积神经网络各具特点。考虑到特征建模能力、数据需求量和部署成本，本文采用卷积神经网络作为基础路线。然而，真实临床应用仍面临多疾病共存导致误检与漏检、模型跨机构泛化性能下降，以及隐私泄露风险等挑战。受以上启发，我们提出自适应标签-特征关联性构建模块，通过 Transformer 机制捕捉疾病共现依赖，减少误检与漏检；设计双分支引导域不变特征提取模块，在多域数据协同训练受限的条件下，仅用单一源域数据并结合 CAM 引导训练，提取域不变特征，提升对未知域的泛化能力，同时利用 CAM 可视化模型关注区域，增强可解释性；集成自适应高斯差分隐私于模型训练过程，通过动态梯度噪声注入，在中等隐私保护下兼顾模型性能。实验部分，通过完整消融验证了各模块的有效性，并使用三个数据集在域内与跨域泛化中取得性能提升，在隐私保护下性能衰减可控。综合以上，本文搭建了一个面向多标签眼科疾病识别的可解释与隐私保护单域泛化框架，提升了多疾病识别任务的跨域泛化性能，并为隐私保护场景下的眼科疾病诊断提供启发。

关键词: Domain Generalization; Multi-Label Ocular Disease Recognition; Data Privacy; Interpretability

1 引言

早期眼底筛查是眼科疾病诊断的有效方法，能够反映视网膜、视盘、血管和黄斑区域的多类病变征象。通过对眼底图像进行分析，有助于患者发现潜在病变并尽早干预，从而降低不可逆的视力损伤甚至视力丧失的风险。随着眼底筛查规模扩大，人工阅片面临阅片耗时、依赖专家经验和基层医疗资源不足等问题，因此基于眼底图像的眼科疾病诊断具有重要应用价值[1]。围绕眼底筛查，现有方法大体可分为传统机器学习、视觉语言模型和卷积神经网络三类路线。传统机器学习通常依赖图像增强、病灶分割、纹理或形态等人工特征，再结合支持向量机、随机森林等分类器完成识别[2]，这类方法具有一定可解释性，但特征设计依赖先验经验，对复杂眼底病灶和多疾病共存场景的表达能力有限。近年来，视觉语言模型为眼底图像理解、图文联合分析和医学报告生成提供了新的研究方向[3][4]，但其训练和微调通常依赖大规模高质量标注数据、图文配对数据以及较高算力资源，在医疗数据稀缺、隐私受限和临床部署资源有限的场景中仍面临较高成本。相比之下，以 CNN 为代表的深度视觉模型能够直接从眼底图像中学习局部纹理、病灶区域和空间结构特征，已广泛应用于疾病识别[5]、病灶分割[6]、医学图像重建[7]和疾病诊断与预测[8]等任务。因此，本文选择 CNN 作为多标签眼科疾病识别任务的基础

路线。然而，在真实临床部署中，基于 CNN 的眼科疾病识别方法仍面临多疾病共存、跨机构部署泛化性能下降以及隐私保护等挑战。具体而言：

1. 在临床眼科疾病诊断中，单只眼睛可能同时存在多种疾病，若仍采用标准单标签分类器或将不同疾病完全独立建模，容易造成误检与漏检[9]。近年来，自然图像中也存在多标签识别方法的相关工作，比如 ML-GCN [10]，通过统计各标签出现的频率建立图关联性，使得识别出某个标签后，更有可能识别出其关联标签，从而减少漏检。而在多标签眼科疾病识别中，各疾病之间的关联性更加错综复杂，仅靠标签频率来建立疾病关联性的方法对于这种复杂情况效果可能不可靠。因此，面向眼底图像的多疾病共存场景，仍需要探索一种更高效可靠的标签-特征关联性构建方法。

2. 医疗图像数据与自然图像不同，其标注通常需要专业医生完成，数据获取和标注成本较高；同时，不同医疗机构之间还存在数据共享限制、标签空间不统一等问题，使多源域数据的访问与协同训练并不总是容易实现。然而，即使通过某个医疗机构的训练集训练得到了一个性能良好的模型，将其应用到另外的机构时，目标域数据也常因成像设备、光照条件和人工处理流程差异产生域偏移[11]，导致模型性能下滑。如图 1.a1和图 1.a3所示，源域和目标域的分布有差异，仅在源域训练的 base model (图 1.b1) 得到的决策边界可能不适用于目标域分布 (图 1.b2)。常见的域适应方法 DA 选择将源域和目标域数据一同送入模型训练来对齐域分布[12]，但这需要训练阶段访问目标域数据；多源域泛化方法虽可避免访问目标域，但通常依赖多个源域共同训练。在医疗数据协同训练受限的实际场景中，上述前提往往难以满足。因此，探索仅利用单一源域提取域不变特征的单域泛化方法，更符合跨机构部署需求。

3. 医疗数据比起自然图像更加敏感，存在更高的隐私泄露风险。常见的攻击方法可以通过模型的训练梯度逆向恢复出患者的数据[13]。针对此问题，目前已有联邦学习、同态加密、安全多方计算和差分隐私等隐私保护方法研究，但是隐私保护与模型性能之间通常存在 trade-off 关系；尤其在 DA 场景中，源域和目标域数据需要同时参与训练，可能带来隐私机制添加复杂、多域性能衰减明显等问题。因此，需要在单域泛化训练流程中进一步探索隐私保护与模型性能之间的平衡方法。

为应对上述三个关键挑战，我们构建了一个面向多标签眼科疾病识别的可解释与隐私保护单域泛化框架。针对眼科疾病识别中普遍存在的多疾病共存问题，我们引入基于 Transformer 的自适应标签-特征关联性构建模块，通过自注意力机制建模标签关联，并利用交叉注意力机制将标签语义与对应的图像特征进行融合，在标签层面与特征层面同时构建疾病共现依赖，从而减少多标签识别中的误检与漏检；针对多机构数据访问受限与跨机构部署域偏移并存的问题，我们提出双分支引导域不变特征提取模块，仅利用单一源域数据进行训练，通过对源域原始图像及其风格扰动后的源域增强图像构建双分支结构（如图 1.a1和图 1.a2所示），在特征层面挖掘两者的共性表示。同时，引入 CAM (Class Activation Mapping) 作为先验引导，促使模型聚焦于疾病相关区域，从而抑制域特定噪声的学习，使得模型能够形成更适用于未知域分布的决策边界 (图 1.c1)，并在未知域上保持稳定的识别性能 (图 1.c2)。此外，CAM 还能够可视化模型关注区域，




图 1: 域偏移场景下常规模型与双分支模型决策边界示意图。(a) 展示源域原始图像（训练集）、源域增强图像和目标域（测试集）的数据分布关系，其中源域增强图像用于模拟目标域可能出现的分布差异；(b) 仅利用源域原始图像训练时，模型学习到的决策边界可能不适用于目标域，因而在目标域样本上产生分类错误；(c) 利用源域原始图像与源域增强图像构建双分支结构，并结合对比学习与 CAM 引导，提取域不变特征后，模型能够学习到更适用于未知域的决策边界。

增强模型的可解释性；针对跨域医疗场景下的隐私泄露风险，本文在单域泛化训练过程中集成自适应高斯差分隐私机制，通过在梯度更新阶段注入噪声实现隐私保护。在中等隐私预算下，该机制能够在不显著牺牲模型性能的前提下提供有效的隐私保护，实现跨域泛化能力与隐私保护的兼顾。

最后，在多个具有代表性的眼底图像数据集上进行的泛化实验表明，该框架在保持良好可解释性的同时，提升了跨域多标签识别性能，并在隐私保护场景下表现稳定。

我们的贡献如下：

1. 提出了一种自适应标签-特征关联性构建模块（Adaptive label-feature relevance construction, ARC），基于 Transformer 的自注意力机制与交叉注意力机制，在标签层面与特征层面同时建模疾病共现依赖，有效降低了多标签眼科疾病识别中的误检与漏检问题。

2. 设计了一种双分支引导域不变特征提取模块（Dual-branch guided domain invariant feature extraction, DFE）。该模块面向多机构数据难联合训练与跨机构部署域偏移并存的场景，通过风格扰动与 CAM 联合引导，仅利用单一源域学习域不变特征，不仅提升了未知域泛化性能，同时增强了模型预测的可解释性。

3. 将自适应高斯差分隐私机制（Adaptive Gaussian differential privacy, AdaGDP）集成至单域泛化训练流程中，在不引入目标域数据的前提下，实现了隐私保护与跨域泛

化性能之间的有效平衡，验证了在中等隐私保护条件下模型性能仍可接近非隐私基线。

本文的其余部分安排如下：第二节介绍了近年来的相关工作。所提方法的具体阐述于第三节介绍，第四节展示完整的实验设置和结果。第五节得出结论并展开未来工作的讨论。

2 相关工作

A. 多标签图像识别

不同于单标签，多标签图像识别允许一幅图像同时对应多个非互斥类别，因此更需要处理疾病共现、标签关联和类别不平衡等问题[14]。早期方法如 Binary Relevance[15]通常将多标签任务简单拆分为多个独立二分类问题，该类方法容易忽略标签之间的相关关系，在复杂视觉场景中，往往会导致预测结果不完整或矛盾。

为缓解上述问题，近年来的多标签图像识别方法逐渐关注标签关联建模和样本不平衡处理。ML-GCN[10]根据疾病共现统计构建标签图，并通过图卷积网络传播标签关联信息；Asymmetric Loss (ASL)[16]对正负样本引入不同的聚焦参数，并通过负样本概率移位机制抑制易分类负样本的损失贡献，从而缓解多标签识别中的正负样本不平衡问题；Query2Label[17]进一步利用 Transformer 查询机制建模标签交互，并在 VOC[18]等自然图像数据集上取得良好效果。这些工作表明，将标签关联显式或隐式地融入模型，有助于提升多标签预测的完整性和准确性。

在医疗眼底图像中，多标签识别具有更强的临床意义，因为同一只眼可能同时存在多种疾病，忽略疾病共存关系容易造成误检与漏检[9]。已有研究从不同角度探索多标签眼科疾病识别问题。例如，Cheng et al.[19]将 ML-GCN 迁移至眼底病灶多标签识别任务，通过构建眼底病灶语料和 GloVe 标签表示建模病灶标签关联；He et al.[20]提出的 DCNet 通过空间相关模块捕捉左右眼眼底图像特征之间的像素级关联，并融合双目特征进行患者级多标签眼科疾病识别；DKCNet[21]利用注意力模块生成判别性区域特征，并结合通道重标定与重采样策略缓解眼科数据集中的类别不平衡问题。

总体而言，现有方法已经能够在一定程度上建模标签关联或缓解类别不平衡，但在眼底多疾病共存场景中，疾病间关系复杂且病灶表现具有局部性，仅依赖疾病共现统计或通用注意力机制仍可能难以稳定刻画标签-特征关联性。因此，面向眼底图像构建更自适应的标签-特征关联性仍具有研究意义。

B. 域泛化

在计算机视觉任务中，模型在训练数据上获得较好性能后，部署到新机构或新设备采集的数据上时，常会受到成像条件、光照环境和数据分布差异的影响而性能下降。这种域偏移在医疗成像中尤为突出，不同医院、设备和采集流程之间的数据差异会直接影响模型泛化能力[22]。域适应 (Domain Adaptation, DA) 是缓解域偏移的常见思路，其核心是在训练过程中利用源域和目标域数据进行分布对齐。例如，基于最大均值差异的 Deep Domain Confusion[23]和相关性对齐方法 CORAL[24]通过缩小特征分布差异提升

迁移性能；DANN[25]采用对抗训练学习域不变特征；CycleGAN[26]及相关无监督域适应方法[27]则通过图像风格转换或跨域对比学习缓解域偏移。然而，DA 通常要求训练阶段能够访问目标域数据，这一前提在医疗数据隐私敏感或目标机构数据不可提前获取的场景中并不总是成立。

与 DA 不同，域泛化（Domain Generalization, DG）旨在不访问目标域数据的条件下学习域不变特征，并泛化到未知域[28]。典型 DG 方法包括 MixStyle[29]，通过混合实例风格统计模拟潜在域偏移；DomainBed[30]提供统一基准以评估不同 DG 算法；FACT[31]从频域角度分解域特定和域不变信息；RSC[32]通过抑制主导特征迫使模型关注更多与类别相关的线索；基于元学习的 DG 方法[33]则通过模拟源域与目标域差异来提升泛化能力。多数 DG 研究通常利用多个带标注源域学习跨域稳定表示，这有助于模型捕捉更丰富的域间变化，但也对标签空间统一、数据处理流程协调和跨机构协作提出较高要求。然而，在真实医疗场景中，上述条件并不总是能够满足，导致多机构数据往往难以集中或同步使用。即使通过联邦学习等方式避免集中存储，也会引入通信、隐私机制、非独立同分布数据和协同优化等额外复杂度。

在此背景下，单域泛化（Single Domain Generalization, SDG）作为更受限的泛化设置，仅使用一个源域学习面向未知域的域不变特征。医疗图像中的 single-source DG 研究[34]也说明，在无法集中使用多机构数据时，从单一源域中挖掘更稳定的疾病相关特征具有现实价值。因此，仅利用单一源域学习域不变特征，是更贴近跨机构多标签眼科疾病识别部署约束的研究方向。

C. 隐私保护

医疗图像和电子健康记录包含高度敏感的个人敏感信息，模型训练、参数共享或云端推理过程均可能带来隐私泄露风险[35]。在医学人工智能应用中，隐私保护不仅关系到患者权益，也受到数据合规要求的约束。常见的隐私保护方案包括联邦学习、加密计算、安全多方计算和差分隐私等。其中，联邦学习（Federated Learning, FL）允许多个客户端在本地训练模型并上传参数或梯度，从而减少原始数据集中共享的需求[36]。例如，FedProx[37]通过添加近端项来处理客户端异构数据，缓解了协同优化不稳定问题。

除联邦学习外，为进一步防范隐私泄露，加密机制可以提供更强隐私保护。同态加密（Homomorphic Encryption, HE）允许在密文上执行计算[38]，并已被探索用于医疗影像分析[39]，但通常伴随较高计算开销；安全多方计算（Secure Multi-Party Computation, SMPC）[40]可在多方协作时保护各方输入隐私；可信执行环境（Trusted Execution Environment, TEE）[41]则通过硬件隔离提供更安全的计算环境。差分隐私（Differential Privacy, DP）通过向查询结果或训练梯度中注入噪声，为单个样本的隐私泄露风险提供可量化约束[42]。其中，高斯差分隐私[43]通过对裁剪后的梯度注入高斯噪声，为连续梯度更新过程提供可量化的隐私保护，因此在深度学习梯度保护中具有较强适用性。

现有隐私保护机制可以降低隐私泄露风险，但在域泛化任务中仍面临额外挑战。联邦学习、同态加密和安全多方计算往往带来通信、计算或系统协同成本；差分隐私虽然部署形式相对直接，但噪声注入可能对模型精度造成影响，且这种影响在不同类别或不

同数据分布上可能并不均衡[44]，这一定程度上增加了多域泛化条件下的隐私保护难度。因此，在单域泛化训练流程中探索更可控的隐私-性能平衡，对于隐私受限场景下的跨机构多标签眼科疾病识别具有实际意义。

3 提出的方法

在多标签眼科疾病识别的域泛化过程中，模型性能主要受到三方面因素影响。首先，同一眼底图像中可能同时存在多种疾病，若模型不能有效建模疾病标签之间以及标签与疾病特征之间的关联，容易产生误检与漏检，从而降低多标签识别性能。其次，源域与目标域之间通常存在分布差异，若模型学习到的特征中包含较多源域特定噪声，则会削弱疾病相关特征的迁移能力，导致域泛化性能下降。此外，隐私保护机制虽然可以降低隐私泄露风险，但也可能通过额外的训练约束影响模型优化过程，因此需要考虑隐私保护与模型性能之间的平衡问题。

针对上述问题，本文首先将多疾病共存和域偏移不视为两个孤立问题，而是统一到多标签眼科疾病识别的单域泛化框架中进行建模。如图 2 所示，所提可解释单域泛化框架主要包括两个部分：Part1. 双分支引导域不变特征提取，Part2. 自适应标签-特征关联性构建。Part1 以 CAM 作为引导，结合双分支 mask 对比学习机制，从单一源域中提取更稳定的域不变特征，缓解源域与未知域之间的分布差异影响。同时 CAM 能够可视化模型关注区域，增强可解释性；Part2 在 Part1 输出的域不变特征基础上，利用 Transformer 注意力机制建模标签-标签关联与标签-特征关联性，减少多标签识别中的误检与漏检。两个部分并非独立工作，而是通过特征过滤和注意力一致性约束形成协同：Part1 为 Part2 提供更稳定的域不变特征，Part2 进一步约束双分支注意力特征的一致性，从而共同提升域泛化性能。最后，训练过程中集成自适应高斯差分隐私机制，以缓解隐私保护机制对模型性能的影响，并在隐私保护与模型性能之间取得平衡。综合以上，所提方法构建了一个面向多标签眼科疾病识别的可解释与隐私保护单域泛化框架。以下分三小节详细描述各模块的实现细节。

A. 双分支引导域不变特征提取

考虑到医疗场景中多机构数据往往难以集中或同步使用，本文采用单域泛化设置，仅利用一个源域学习面向未知域数据的域不变特征。受对比学习启发，本文将源域原始图像利用风格扰动等增强技术创建源域增强图像，用于模拟未知域可能出现的分布差异。具体而言， I^{ori} 代表源域原始图像，而 I^{aug} 代表源域增强图像，通过风格扰动（如 MixStyle 方法或随机调整亮度、对比度、饱和度）生成。这种增强模拟了跨域场景中的成像设备、光照环境或患者群体差异，但保留了图像的语义内容（疾病区域）。

首先，如图 2.a 部分所示， I^{ori} 和 I^{aug} 二者共同送入骨干网络提取特征得到 F^{ori} 和 F^{aug} 。令 $F^{ori} \in \mathbb{R}^{C \times H \times W}$ 和 $F^{aug} \in \mathbb{R}^{C \times H \times W}$ ，其中 C 、 H 、 W 分别为骨干网络最终特征图的通道数、高度和宽度。本方法选择 ResNet50 作为骨干网络，因为其在医疗图像分类中表现出色，具有较好的特征提取能力和计算效率。然而，仅依靠源域原始图像与源域增强图像之间的对比约束仍然有限，模型可能同时学习到背景纹理、光照变化或边




图 2: 所提可解释单域泛化框架总览。Part1 为双分支引导域不变特征提取 (DFE), 由 (a)–(c) 组成: 首先 (a) 将源域原始图像与源域增强图像输入骨干网络提取双分支特征; 同时 (b) 利用 CAM 生成模型关注区域引导, 以增强疾病相关区域并抑制背景噪声; 最终 (c) 通过双分支 mask 对比学习机制保留两路特征中的高度相似部分, 从而提取域不变特征。Part2 为自适应标签-特征关联性构建 (ARC), 由 (d)–(e) 组成: 其中 (d) 利用 Transformer 自注意力机制建模标签-标签关联, 再通过交叉注意力机制建立标签-特征关联性, 然后由 (e) 利用注意力一致性约束提升注意力特征的稳定性, 从而减少多标签识别中的误检与漏检。Part1 和 Part2 协同工作, 模型能够在提取域不变特征的同时更有效地建模标签关联, 从而共同提升域泛化性能。

缘伪影等域特定噪声, 进而影响未知域上的多标签眼科疾病识别。

为此, 我们引入图 2.b 部分的类别特征引导模块, 以提升特征的疾病相关性和可解释性。预先使用基线模型 (ResNet50 + BCE 损失) 在训练集上生成 CAM。CAM 突出模型对不同疾病区域的关注, 例如糖尿病视网膜病变 (DR) 关注血管区, 年龄相关性黄斑变性 (AMD) 关注黄斑区。其计算公式为:

$$I^{cam} = \sum_{k=1}^C w_k \cdot A_k,$$

其中 A_k 是骨干网络最后一层卷积的第 k 个通道激活图, w_k 是通过全局平均池化后对分类权重的梯度计算得到的权重。该公式基于 Grad-CAM 变体, 确保 CAM 捕捉类别特定模型关注区域。生成的 CAM I^{cam} 输入骨干网络得到 $F^{cam} \in \mathbb{R}^{C \times H \times W}$, 然后通过空间/通道注意力模块分别计算 F^{cam} 的空间注意力权重 s_w 和通道注意力权重 c_w 。两个注意力模块均为卷积序列网络, 都包含有 1x1 卷积、ReLU 激活和 Sigmoid 函数, 用于自适应生成权重。空间注意力模块额外结合平均/最大池化捕捉局部上下文, 从而

生成像素级权重图，自适应放大病变区域（如血管或黄斑）的显著性，同时抑制背景噪声。通道注意力模块则采用自适应平均池化压缩空间维度以获取全局统计，随后学习通道依赖，从而增强疾病纹理敏感通道的权重，抑制噪声通道。分别将两权重加权应用到 F^{ori} 和 F^{aug} 得到 CAM 引导特征 F_{guide}^{ori} 和 F_{guide}^{aug} ，具体的加权方式采用残差连接机制，避免过度引导破坏原始信息。公式为：

$$\begin{aligned} F_{guide}^{ori} &= F^{ori}(1 + \alpha \cdot s_w)(1 + \beta \cdot c_w), \\ F_{guide}^{aug} &= F^{aug}(1 + \alpha \cdot s_w)(1 + \beta \cdot c_w), \end{aligned}$$

其中 α 和 β 分别为控制 s_w 和 c_w 增强程度的超参数。残差加权方式使 CAM 引导信息在保留原始特征表达的同时突出疾病相关区域，减少模型对光照、背景纹理等域特定噪声的依赖。在此基础上再提取域不变特征，有助于提升特征的疾病相关性；同时 CAM 的模型关注区域可视化也增强了模型的可解释性，帮助临床医生理解预测依据，例如通过叠加 CAM 观察模型是否关注病变区域。

接下来是域不变特征过滤模块，如图 2.c 所示。本文采用双分支 mask 对比学习机制，将源域原始图像引导特征和源域增强图像引导特征在特征分布层面计算相似度，相似度高的部分代表在风格扰动下仍保持稳定的疾病相关区域，予以保留；相似度低的部分更可能包含光照、设备风格或风格扰动带来的域特定噪声，予以抑制。掩码矩阵 $M \in \mathbb{R}^{C \times H \times W}$ 的计算基于标准化距离：

$$M_{ij} = \begin{cases} 1, & \text{if } \left| \frac{F_{guide}^{ori,ij} - \mu_1}{\sqrt{\sigma_1^2 + \epsilon}} - \frac{F_{guide}^{aug,ij} - \mu_2}{\sqrt{\sigma_2^2 + \epsilon}} \right| \leq \tau, \\ 0, & \text{otherwise.} \end{cases}$$

其中 μ_1, σ_1 和 μ_2, σ_2 分别是两个引导特征的均值和方差， $\epsilon = 10^{-5}$ 为稳定性常数， i, j 表示特征图位置。然后根据阈值 τ 将相似部分置 1，不相似置 0。最终将掩码矩阵分别应用到 F_{guide}^{ori} 和 F_{guide}^{aug} 提取域不变特征，具体为：

$$F_{invariant}^{ori} = F_{guide}^{ori} \odot M, F_{invariant}^{aug} = F_{guide}^{aug} \odot M,$$

其中 $\odot$ 是像素级逐元素乘法，确保只保留共有的疾病相关特征，如血管或黄斑区纹理，而剔除光照或设备噪声。由此得到的 $F_{invariant}^{ori}$ 和 $F_{invariant}^{aug}$ 作为后续标签-特征关联性构建的输入，使多标签关联学习建立在更稳定的域不变特征之上。

B. 自适应标签-特征关联性构建

在获得域不变疾病特征后，模型将进一步处理眼科疾病共存带来的多标签关联问题。为此，本文嵌入 Transformer 注意力机制，在标签和特征层面构建自适应关联，实现多标签预测。具体模块如图 2.d 和图 2.e 所示，包括多标签关联构建和注意力特征对齐。

首先，将 8 类标签（ODIR 数据集：正常、DR、AMD 等）建模为可学习向量 $L = [L_1, \dots, L_8] \in \mathbb{R}^{8 \times d}$ ，其中 $d = 512$ 是嵌入维度。这些向量初始化为随机高斯分布，并在

训练中优化，便于刻画不同疾病标签之间的潜在关联。标签向量输入到 Transformer 自注意力机制 (Self-Attention)，建模标签关联：

$$V_{self} = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V,$$

其中 $Q = LW_Q, K = LW_K, V = LW_V$, W_Q, W_K, W_V 是可学习投影矩阵, $d_k = d/\text{heads}$ (多头注意力, $\text{heads}=8$)。自注意力输出 V_{self} 用于捕捉标签关联，使不同疾病标签能够根据训练数据中的共现模式和视觉证据进行动态交互。

接下来，使用交叉注意力机制 (Cross-Attention) 将标签与域不变特征结合。因为 Transformer 需要接收序列输入，我们先将 Part1 输出的 $F_{invariant}^{ori}$ 和 $F_{invariant}^{aug}$ 展平 (Flatten)，作为 Key 和 Value，与标签向量 V_{self} 作为 Query，进行交叉注意力计算。计算公式为：

$$V_{cross}^{ori} = \text{softmax} \left(\frac{V_{self} W_Q (F_{invariant}^{ori} W_K)^T}{\sqrt{d_k}} \right) (F_{invariant}^{ori} W_V),$$

类似计算 V_{cross}^{aug} 。通过多层交叉注意力机制，标签与对应疾病特征进行匹配，形成注意力向量 $V \in \mathbb{R}^{8 \times d}$ ，突出疾病相关区域（如像素级乘法增强病变区）。在这一过程中，每个标签向量并不是独立地与图像特征进行匹配，而是在自注意力机制建模后的标签关联基础上进行查询。因此，模型既能关注单个疾病对应的局部病灶特征，也能利用疾病共现依赖辅助判断其他相关标签，从而减少多标签识别中的误检与漏检。

为了确保双分支向量输出一致，我们引入注意力一致性约束，并计算注意力一致性损失。源域原始图像和源域增强图像具有相同的疾病标签，只是二者存在风格差异，因此对应的标签注意力向量也应保持接近。该损失通过约束两条分支的注意力特征一致，使模型在不同风格输入下仍学习到相近的标签-特征关联性。具体计算方式为均方误差 (MSE)，公式为：

$$L_{consist} = \frac{1}{N \cdot d} \sum_{k=1}^N \sum_{j=1}^d \left(\text{softmax}(V_k^{ori})_j - \text{softmax}(V_k^{aug})_j \right)^2,$$

其中 $N = 8$ 是标签数， $d = 512$ 是嵌入维度，Softmax 用于将注意力向量归一化为可比较的分布形式。注意力一致性损失通过最小化两分支归一化注意力特征之间的差异，提升模型在域偏移下的稳定性。

最终，注意力向量输入多标签分类器，首先对类别查询特征施加 LayerNorm 与 Dropout 以进行轻量级特征增强，以规范化和正则化查询特征，随后通过逐类别的线性变换获得每个类别的 logits，经 Sigmoid 激活后，得到各类别的预测概率 p^{ori} ，类似得到 p^{aug} 。分类损失采用二元交叉熵 (BCE)：

$$L_{cls}^{ori} = -\frac{1}{8} \sum_{k=1}^8 [y_k \log p_k^{ori} + (1 - y_k) \log(1 - p_k^{ori})],$$

总损失为 $L = L_{cls}^{ori} + L_{cls}^{aug} + \lambda L_{consist}$ ，其中 λ 为平衡一致性程度的超参数。通过上述设计，DFE 模块为 ARC 模块提供与疾病相关的域不变特征，ARC 模块进一步建模标签-标签关联性及标签-特征关联性，二者协同提升跨域场景下的多标签识别能力。

C. 隐私保护集成

医疗图像数据高度敏感，训练过程中产生的梯度或模型参数可能泄露样本信息，其中梯度逆向攻击甚至可能恢复原始图像，导致隐私泄露风险。考虑到单域泛化模型的隐私保护与模型性能的平衡问题，本文引入自适应高斯差分隐私（Adaptive Gaussian differential privacy, AdaGDP）机制。整体的隐私保护框架如图 3 所示。




图 3: 自适应高斯差分隐私在单域泛化框架中的集成方式。训练过程中，每步更新均先对样本梯度进行裁剪，再注入高斯噪声并完成参数更新；与固定噪声差分隐私不同，本文采用随训练阶段自适应调整并逐步衰减的噪声乘数，从而在训练前期提供较强隐私保护，在训练后期减小噪声对模型收敛的干扰，进而取得隐私-性能平衡。

高斯差分隐私 (GDP) 通过在每步梯度更新时加入独立同分布的高斯噪声实现 (ϵ, δ) -差分隐私。对于相邻数据集 D 和 D' （仅相差一个样本），若随机算法 M 对任意输出集合 S 满足：

$$\Pr[M(D) \in S] \leq e^\epsilon \Pr[M(D') \in S] + \delta,$$

则称 M 满足 (ϵ, δ) -DP，其中 ϵ 衡量隐私保护程度， δ 为松弛项，通常设为 10^{-5} 。在 DP-SGD 框架下，每次迭代对每个样本梯度 g 先进行 L2 范数裁剪：

$$g' = g / \max(1, \|g\|_2 / C),$$

然后加入高斯噪声 $n \sim \mathcal{N}(0, \sigma^2 C^2 I)$ ，其中 σ 为噪声乘数，用于控制噪声强度，通常与隐私预算 ϵ 和松弛项 δ 相关，可写为：

$$\sigma = \sqrt{2 \ln(1.25/\delta)}/\epsilon.$$

噪声梯度 $\tilde{g} = g' + n$ ，更新 $\theta \leftarrow \theta - \eta \tilde{g}/B$ ，其中 B 是批次大小。该过程通过注入噪声模糊梯度，防止逆向攻击恢复原始图像或标签。有关隐私保护机制及其安全性的详细证明，请参阅 Dwork C et al.[45]的工作。

然而，传统 GDP 在整个训练过程中使用固定 σ ，导致训练后期仍注入大量噪声，容易影响模型收敛和最终性能。为此，我们采用自适应高斯差分隐私优化器，在训练初期使用较大噪声乘数提供较强保护，随后根据预设噪声衰减速率逐步降低噪声强度，以减小后期对模型收敛的影响。训练过程中，本文根据每轮噪声乘数、噪声衰减速率和采样过程累计隐私预算，并记录不同训练轮次下的 ϵ 消耗与模型性能变化，用于分析隐私预算增长过程中的性能演化。最终实验验证，在中等隐私预算下，所提方法能够缓解噪声注入带来的性能下降，在隐私保护与模型性能之间取得较好的平衡。

4 实验

A. 数据集

本实验采用 ODIR-5K (Ocular Disease Intelligent Recognition) [46]数据集作为单一源域。ODIR 包含 5000 名患者的 10000 张彩色眼底图像（左右眼各 5000 张），由 3 名具有 2 年以上临床经验的眼科医生初步标注，并由 3 名 10 年以上经验的专家进行最终仲裁。数据集定义了 8 个互不排斥的类别：正常 (N)、糖尿病视网膜病变 (D)、青光眼 (G)、白内障 (C)、年龄相关性黄斑变性 (A)、高血压视网膜病变 (H)、病理性近视 (M) 和其他异常 (O)，如图 4.a 到图 4.h 所示，属于典型的多标签眼科疾病识别任务。每张图像可能同时具有多个疾病标签，患者级标签由其左右眼诊断关键词综合确定。官方将 5000 名患者划分为 3 个子集，训练集 (3500 人) 用于模型训练，Off-site test 集 (500 人) 用于模型选择，On-site test 集 (1000 人) 用于测试模型域内泛化性能。各类别分布如表 1 所示，存在类别不平衡问题。

表 1: ODIR 数据集各类别在训练集、On-site test 集与 Off-site test 集中的样本分布。正常类 (N)、糖尿病视网膜病变 (D) 和其他异常 (O) 样本数相对较多，而高血压视网膜病变 (H) 样本数最少，类别间分布差异明显，存在类别不平衡问题。

Labels	N	D	G	C	A	H	M	O
Training	1138	1130	215	212	164	103	174	982
On-site test	324	327	58	65	49	30	46	275
Off-site test	162	163	32	31	25	16	23	136
All	1624	1620	305	308	238	149	243	1393




图 4: ODIR 数据集中 8 类眼底图像的示例样本, 对应本文使用的 8 个非互斥类别。其中 (a)-(h) 分别代表 (a) 正常 (N), (b) 糖尿病视网膜病变 (D), (c) 青光眼 (G), (d) 白内障 (C), (e) 年龄相关性黄斑变性 (A), (f) 高血压视网膜病变 (H), (g) 病理性近视 (M), (h) 其他异常 (O)。

为全面评估模型的域泛化能力, 除 ODIR 域内泛化外, 本文额外引入 RIADD 挑战赛提供的 RFMiD[47]数据集作为第一个独立跨域泛化数据集。RFMiD 包含 3200 张彩色眼底图像, 训练集、验证集和测试集分别包含 1920、640 和 640 张图像, 涵盖 45 种视网膜疾病或异常, 由专业视网膜专家标注。其 45 类标签中含有部分与 ODIR 的 8 类标签重合的类别, 这为模型泛化提供了基础。图 5.a 到图 5.h 选择性地展示了 45 种类别中的 8 类图像。考虑到 RFMiD 与 ODIR 的完整标签空间并不一致, 本文选取二者共有的糖尿病视网膜病变 (D)、年龄相关性黄斑变性 (A) 和病理性近视 (M) 三类进行跨域泛化。在该设置下, ODIR 侧构建得到 1907 张 D/A/M 三类训练图像, 其中 D、A、M 的标签数分别为 1425、255 和 253; RFMiD 侧使用验证集中的 119 张三类图像进行测试, 其中 D、A、M 的标签数分别为 83、24 和 21。

此外, 本文引入来自于 Anawara Hamida 和 B.N.S.B. Zahurul Haque 眼科医院采集的 EDID[48]数据集作为第二个独立跨域泛化数据集, 以进一步验证所提方法在不同数据来源和不同标签组织方式下的泛化性能。EDID 原始数据共包含 5335 张眼底图像, 覆盖 10 个单标签类别, 包括中心性浆液性脉络膜视网膜病变、糖尿病视网膜病变、视盘水肿、青光眼、正常眼底、黄斑瘢痕、近视、翼状胬肉、视网膜脱离和视网膜色素变性, 对应样本数分别为 101、1509、127、1349、1024、444、500、17、125 和 139。图 6.a 到图 6.h 展示了 EDID 数据集中选取的 8 类典型眼底图像示例。

与 RFMiD 类似, 考虑到 EDID 与 ODIR 的完整标签空间并不一致, 本文选取二者共有的糖尿病视网膜病变 (D)、青光眼 (G) 和病理性近视 (M) 三类构建跨域泛化数据集, 共得到 3358 张图像, 其中 D、G、M 的样本数分别为 1509、1349 和 500。由于 EDID 为单标签数据集, 本文将其视为多标签识别任务中的一种特殊情形, 即每张图像仅有一个阳性标签, 并在 D/G/M 三类空间下进行跨域泛化评估。相应地, 在 ODIR




图 5: RFMiD 数据集中选取的 8 类眼底图像示例, 其中 (a)-(h) 分别对应 (a) 糖尿病视网膜病变 (D), (b) 年龄相关性黄斑变性 (A), (c) 近视 (M), (d) 黄斑瘢痕 (MS), (e) 视网膜炎 (RS), (f) 中心性浆液性脉络膜视网膜病变 (CSR), (g) 视网膜中央静脉阻塞 (CRVO), (h) 视盘水肿 (DE)。RFMiD 作为跨域泛化数据集使用, 实验中与 ODIR 对齐后的共有标签空间为 D/A/M 三类, 用于评估跨域泛化性能。




图 6: EDID 数据集中选取的 8 类眼底图像示例, 其中 (a)-(h) 分别对应 (a) 糖尿病视网膜病变 (D), (b) 青光眼 (G), (c) 近视 (M), (d) 视网膜脱离 (RD), (e) 视网膜色素变性 (RP), (f) 视盘水肿 (DE), (g) 黄斑瘢痕 (MS), (h) 中心性浆液性脉络膜视网膜病变 (CSR)。EDID 为单标签跨域泛化数据集, 实验中与 ODIR 对齐后的共有标签空间为 D/G/M 三类, 用于评估不同数据来源和标签组织方式下的泛化性能。

侧构建 D/G/M 三类训练子集, 共包含 1871 张图像, 其中 D、G、M 的样本数分别为 1401、227 和 243。

B. 实验设置

所有实验均以 ResNet50 作为骨干网络, 并在 PyTorch 框架下实现。评估指标沿用 ODIR 官方标准: Kappa 系数、F1、AUC 以及三者平均值 Final score。Kappa 阈值固定为 0.5, F1 采用 micro 平均方式以缓和类别不平衡影响。

对于基线模型，我们参考 ODIR 原始的 ResNet50 的实现，并在此基础上进行了改进：原论文采用双目样本成对输入，尝试不同的特征层融合策略（如 concat、prod、sum）后接 8 个独立的分类头进行患者级预测。而我们改为以单目图像为输入样本，样本同时带有所属患者的编号，分类器统一为单个多标签分类头，输出 8 维 logits 后经 Sigmoid 激活得到各疾病概率，损失函数为标准二元交叉熵（BCE）。推理阶段，将同一患者左右眼的单目预测结果按逻辑合并得到患者级预测，从而与官方指标完全对齐。该改进避免了特征融合带来的噪声放大和个体差异信息稀释，尤其在双目病变程度不一致时更有优势。

训练配置如下：优化器选择 Adam，初始学习率 1×10^{-5} ，采用 OneCycleLR 调度策略（前 10% 轮次线性升温至峰值 1×10^{-5} ，有助于模型快速跳出局部最优，后 90% 轮次退火，有助于收敛和找到更优解），训练 epoch 为 50，batch size 为 32，输入分辨率为 448×448 。所提方法在 2 张 RTX 4080 Super 上完成训练。后续实验结果表明，我们的改进基线模型（Off-site 双目 Final score 76.19）比起 ODIR 原文 ResNet50 实现（Off-site 双目 Final score 68.00）能达到更好的效果。

C. 与现有方法对比

为评估所提方法在 ODIR 数据集上的识别性能，我们选取了四个典型的多标签眼科疾病识别方法，包括 ODIR 数据集论文提供的官方基线（Li et al.[46]）以及三项后续工作（Gour and Khanna[49]、He et al.[20]、Ou et al.[50]）。这些方法主要聚焦于提升 Final score，未考虑跨域泛化或隐私保护。

Gour and Khanna[49]提出基于转移学习的 CNN 框架，骨干网络采用 VGG16，通过数据增强方法扩充 ODIR 数据集，然后采用 SGD 优化器细调模型，焦点在于利用预训练权重捕捉血管、视盘、黄斑等结构异常，以提升多类共存场景的识别性能。

He et al.[20]开发密集相关网络（DCNet），包括骨干 CNN 提取双目特征、空间相关模块捕捉像素级相关性，以及分类器生成患者级分类结果。核心原理是通过密集卷积块融合双目特征，建模 DR 与 AMD 等疾病共现，但需依赖双目输入。

Ou et al.[50]设计双流交互 CNN，使用特征增强模块通过注意力机制捕捉双目局部-全局依赖，并多尺度模块叠加不同分辨率特征以丰富表示。其原理在于利用双流交互强化病变区域（如微血管瘤、出血点），提升多标签识别性能，但未考虑隐私或跨域场景。

表 2 报告了 Off-site test 和 On-site test 集上的双指标对比。对比结果显示，所提方法在 Off-site 的 Final score 为 78.85，领先 BFENet [50] 0.85；在 On-site 为 77.49，领先 BFENet [50] 0.79。该结果证明了双分支引导特征学习与自适应标签-特征关联性构建在 ODIR 多标签识别任务中的有效性。

需要指出的是，现有对比方法主要围绕 ODIR 内部多标签识别指标进行优化，较少同时考虑域泛化和隐私保护。相比之下，本文除在 ODIR Off-site 和 On-site 上取得更高 Final score 外，还在 RFMiD 和 EDID 两个跨域泛化数据集上验证了未知域性能，并进一步评估隐私保护训练下的性能衰减。上述结果共同说明，所提方法不仅追求单一数

表 2: 与现有方法在 ODIR Off-site 和 On-site 上的双目指标对比。红色表示各指标中的最优结果, 蓝色表示次优结果。与 BFENet[50] 相比, 所提方法虽然在 F1 和 AUC 两项指标上略低, 但在 Kappa 上提升更明显, 并在两个测试集上的 Final score 均取得了最优结果。

Method	Off-site				On-site			
	Kappa	F1	AUC	Final	Kappa	F1	AUC	Final
Li et al. [46]	35.45	84.83	83.72	68.00	36.97	85.35	84.08	68.80
Gour and Khanna [49]	43.30	85.30	84.90	71.20	42.00	84.90	83.40	70.10
He et al. [20]	52.00	88.60	90.30	77.00	50.00	87.70	89.70	75.80
BFENet [50]	53.50	89.20	91.20	78.00	51.30	88.60	90.30	76.70
Ours	57.05	89.03	90.48	78.85	54.03	88.38	90.07	77.49

据集上识别性能, 也面向更贴近临床部署的数据共享受限和隐私保护场景。

D. 消融实验结果

为系统验证所提方法中两大核心模块, 即双分支引导域不变特征提取 (DFE) 与自适应标签-特征关联性构建 (ARC) 的独立贡献及协同增益, 同时考察 CAM 引导对模型可解释性的提升, 我们在 ODIR Off-site 双目指标上进行了逐模块消融实验, 结果如表 3 所示。

表 3: 消融实验结果。表中报告了在 ODIR Off-site test 集下的双目指标。结果显示, DFE 和 ARC 相比 ResNet50 (baseline) 在 Final score 上均带来性能提升, 分别提升 2.18 和 0.79; 二者协同后进一步取得更高的指标提升, 总体提升 2.66, 并在四项指标上达到最佳结果, 体现了两模块之间的正向协同作用。

Model	Kappa	F1	AUC	Final
ResNet50	52.75	87.83	88.00	76.19
ResNet50+DFE	56.20	88.80	90.10	78.37
ResNet50+ARC	53.19	87.45	90.29	76.98
ResNet50+DFE+ARC (Ours)	57.05	89.03	90.48	78.85

- ResNet50: 仅使用单分支 ResNet50 与标准多标签分类头, Final score 为 76.19, Kappa 为 52.75, AUC 是 88.00。
- ResNet50+DFE: 仅引入完整的双分支引导域不变特征提取模块, Final score 提升至 78.37 (+2.18), Kappa 提升 3.45, AUC 提升 2.10。性能提升主要源于 CAM 引导残差加权与掩码机制有效抑制了域特定噪声, 使模型更关注域不变特征, 是整体性能提升的重要来源。

- ResNet50+ARC: 仅引入自适应标签-特征关联性构建模块, Final score 提升至 76.98 (+0.78), Kappa 提升 0.44, AUC 提升 2.29。该模块通过显式建模疾病共现依赖 (如 DR 与 AMD、近视与视盘异常) 降低了漏检率, 多标签识别性能提高。
- ResNet50+DFE+ARC (所提方法, ours): 同时启用两大模块协同后, Final score 进一步升至 78.85 (较基线 +2.66), Kappa 达到 57.05 (+4.30), F1 与 AUC 分别达到 89.03 (+1.20) 和 90.48 (+2.48)。总增益与两模块增益之和接近 ($2.66 < 2.18+0.78=2.96$), 体现了两模块之间的正向协同: DFE 为 ARC 提供更稳定的域不变特征, 使 Transformer 能更精准地学习标签-标签关联性与标签-特征关联性; ARC 的注意力一致性损失反过来进一步约束双分支输出分布, 提升特征表示的稳定性。进一步从图 7 的可视化结果可以看出, 相比 baseline, 所提方法得到的 CAM, 其模型关注区域对图像边缘、光照伪影的响应减少, 更收敛到眼球、血管等疾病相关区域, 模型可解释性增强。




图 7: 基线方法与所提方法在 ODIR Off-site 部分样本上的 CAM 的模型关注区域可视化对比, 其中 (a)–(j) 为不同测试样本。相比基线模型, 所提方法的模型关注区域更集中于眼球、血管和疾病相关区域, 对图像边缘、光照伪影等无关背景的响应更弱, 说明所提方法能够有效抑制域特定噪声并增强可解释性。

消融结果证明: 自适应标签-特征关联性构建 (ARC) 验证了标签关联建模对多疾病共存场景的有效性, 双分支引导域不变特征提取 (DFE) 验证了在多机构联合训练难以满足时, 仅利用单一源域学习域不变特征的必要性。两模块的深度融合协同使得所提方法在仅使用单一源域训练的情况下进一步提升多标签识别性能, 并为后续跨域泛化结果提供支撑, 体现了本方法设计的科学性与高效性。

E. 泛化性能结果

为全面验证所提方法在单一源域训练条件下的泛化能力以及隐私保护机制的有效性, 我们分别在非隐私和隐私保护两种场景下进行了系统性评估, 涵盖 ODIR 域内泛化 (Off-site 与 On-site) 和跨域泛化 (RFMiD 与 EDID)。

(1) 非隐私条件下的泛化性能结果如表 4 所示, 表中报告了基线模型与所提方法在不同测试集上的 Final score。泛化实验按三个评估方向组织: ODIR 域内的 Off-site →

On-site、ODIR 到 RFMiD 的跨域泛化，以及 ODIR 到 EDID 的跨域泛化。每个方向均基于训练过程中保存的前 5 个候选检查点进行模型选择与评估，即分别在基线模型和所提方法的候选检查点中确定测试集表现最优的一组检查点，并同步报告该组检查点在源域 Off-site 和目标域上的结果。

表 4: 不同测试集上的泛化性能比较。比较了基线模型与所提方法在 ODIR 域内泛化 (Off-site $\rightarrow$ On-site) 以及 ODIR 到 RFMiD、EDID 跨域泛化中的表现，比较的指标均为 Final score。其中，Off-site $\rightarrow$ On-site 同时报告了单目与双目结果，跨域泛化部分报告了各数据集对齐三类标签空间后的单目结果；每个方向均在候选检查点中选择测试集表现最优的模型进行报告。总体上，所提方法在各测试方向上均优于基线模型。

Model	Off-site $\rightarrow$ On-site				Off-site $\rightarrow$ RFMiD		Off-site $\rightarrow$ EDID	
	Off-site		On-site		Off-site	RFMiD	Off-site	EDID
	Monocular	Binocular	Monocular	Binocular	Monocular	Monocular	Monocular	Monocular
ResNet50	79.37	76.19	77.30	75.23	94.39	83.86	94.30	52.16
Ours	81.71	78.79	78.98	77.49	95.94	85.06	96.03	55.35

在 ODIR 域内泛化中，测试集为 On-site，表 4 同时报告单目 (Monocular) 和双目 (Binocular) 两种评估方式。基线模型对应检查点在 Off-site 和 On-site 上的双目指标分别为 76.19 和 75.23，而所提方法对应检查点将指标提升至 78.79 和 77.49，增幅分别达 2.60 和 2.26 个百分点；单目指标同样由 79.37 和 77.30 提升至 81.71 和 78.98。这说明双分支引导特征学习与 CAM 引导注意力能够增强模型对疾病相关区域的关注。其中双目指标低于单目指标的原因是，模型本身以单目数据进行训练，推理阶段将同一患者左右眼预测结果合并时，任一只眼的错误预测都可能影响患者级判断，从而放大单目小错误对最终指标的影响。

在跨域泛化中，RFMiD 和 EDID 与 ODIR 的完整标签空间并不一致，因此本文先重构共有三类标签空间，再进行泛化评估。其中 RFMiD 实验对齐 D/A/M 三类，EDID 实验对齐 D/G/M 三类；EDID 虽然为单标签数据集，但同样可在三类共有标签空间下作为跨域泛化数据集。考虑到跨域泛化数据集与 ODIR 在成像设备、采集流程、光照条件、疾病组成和标签定义上存在更明显差异，本文同样基于前 5 个候选检查点进行模型选择与评估，并同步报告该组检查点在三类 ODIR Off-site 和跨域泛化数据集上的单目 Final score。

结果显示，在 RFMiD D/A/M 跨域泛化中，基线模型对应检查点的 ODIR Off-site 的 Final score 为 94.39，目标域的 Final score 为 83.86；所提方法对应检查点的 ODIR Off-site 的 Final score 为 95.94，目标域 Final score 为 85.06，分别提升 1.55 和 1.20 个百分点。进一步从细分指标看，所提方法在 RFMiD 上的 Kappa、F1 和 AUC 分别为 73.95、87.96 和 93.27，均高于基线模型的 72.08、87.11 和 92.39。在 EDID D/G/M 跨域泛化中，基线模型对应检查点的 ODIR Off-site 的 Final score 为 94.30，目标域 Final score 为 52.16；所提方法对应检查点的 ODIR Off-site 的 Final score 为 96.03，目标域 Final score 为 55.35，分别提升 1.73 和 3.19 个百分点。所提方法在 EDID 上的 Kappa、

F1 和 AUC 分别为 27.20、67.22 和 71.63，较基线模型的 23.83、65.54 和 67.09 均有提升。综合来看，RFMiD 结果验证了模型在多标签数据集上的跨域泛化能力；EDID 结果进一步说明，在单标签数据集被纳入三类泛化评估框架的情况下，所提方法仍能保持有效提升。

(2) 自适应高斯差分隐私超参数扫描结果如表 5 所示。引入隐私保护后，噪声注入速率会一定程度影响模型收敛行为与最终性能。实验发现，噪声乘数 (noise_multiplier) 与噪声衰减速率 (noise_decay_rate) 共同决定了每轮噪声注入速率，并进一步影响每轮隐私预算消耗：过强的初始噪声会导致训练剧烈震荡甚至不收敛，而过快的衰减则使隐私预算在模型尚未充分学习时提前耗尽。其中，setting1 (noise_multiplier=0.65) 提供了极强的隐私保护，但因初始噪声过大，导致 ϵ 值仅为 5.01，使模型性能严重下降；setting8 (noise_multiplier=0.25, decay_rate=4e-6) 虽然使得模型性能接近非隐私情况，但是 $\epsilon \approx 20$ 隐私保护弱。综合性能与隐私预算，我们最终选取 setting5 (noise_multiplier=0.35, decay_rate=4e-6)，在 80 epoch 后 $\epsilon \approx 10.15$ ，实现了较优的隐私-性能平衡。

表 5: 自适应高斯差分隐私超参数扫描结果。表中比较了不同噪声乘数与噪声衰减速率组合在 80 epoch 差分隐私训练设置下对应的隐私预算 ϵ 。其中，setting1 下噪声注入较强，虽然隐私保护更好，但模型性能下滑较大；setting8 下噪声注入相对较缓，模型性能下滑较小，但隐私保护较弱。而红色的 setting5 为本文最终采用的设置，在隐私保护与模型性能之间取得了较好平衡。

Setting	noise_multiplier	noise_decay_rate	ϵ / 80 epoch
setting1	0.65	1.5e-6	5.01
setting2	0.50	2e-6	6.80
setting3	0.40	4e-6	8.71
setting4	0.35	2e-6	9.96
setting5	0.35	4e-6	10.15
setting6	0.30	2e-6	11.91
setting7	0.25	2e-6	15.11
setting8	0.25	4e-6	20.01

(3) 隐私训练过程中的 ϵ -性能演化与优化策略结果如表 6 所示。采用 setting5 的噪声速率后，我们记录了训练过程中 ϵ 消耗与单目指标的逐 epoch 变化。结果显示，随着 ϵ 从第 0 轮的 0.94 逐步增长至第 79 轮的 10.15，隐私逐步消耗，模型性能持续提升，至第 74 轮附近达到峰值 (Final=73.15)。这表明自适应衰减策略允许模型在隐私预算内充分学习。第 74 轮的检查点是兼具隐私保护和性能的最佳平衡点。经过大量实验验证，隐私场景需对优化策略进行针对性调整：

1. 学习率从 1×10^{-5} 提升至 7.5×10^{-5} 。
2. 学习率调度改为“先线性衰减后恒定”：以 lr_decay_ratio 和 lr_final_factor 控制衰减轮次和衰减比例，所取值分别为 0.75 和 0.8，即学习率在前 75% 轮次内线性衰

表 6: 隐私训练过程中 ϵ 与性能的演化。表中使用的是表 5 中 setting5 的加噪策略, 评估指标是单目下的 Final score, 随着训练推进, 隐私预算逐步消耗、模型性能总体上升, 并在 e74 达到峰值 (红色部分)。此检查点将作为本文在隐私保护下采用的最优隐私检查点。

Epoch	ϵ	Kappa	F1	AUC	Final
e0	0.94	29.39	84.70	78.70	64.26
e10	3.28	34.24	85.77	81.27	67.09
e22	4.91	36.42	85.85	82.83	68.36
e31	5.91	39.70	86.28	83.56	69.85
e40	6.81	40.62	86.13	84.08	70.28
e49	7.65	40.64	87.01	85.17	70.94
e52	7.92	42.16	87.46	85.00	71.54
e64	8.94	42.45	87.38	85.89	71.91
e68	9.27	43.59	87.76	86.18	72.51
e74	9.76	45.12	87.91	86.42	73.15
e79	10.15	43.16	87.51	86.47	72.38

减至原值的 80%, 之后保持恒定训练。

原因在于, 隐私情况下的模型训练和常规情况下的模型训练不一样。对于学习率的取值来说, 隐私情况下, 每一次回传的梯度中都会叠加噪声, 这使得每一次模型优化时的损失值在原基础上波动, 增大了陷入局部最优的概率, 因此学习率需要适当增大。对于学习率调度策略, 在常规情况下当模型收敛到最优值附近时, 非隐私训练的学习速率通常会逐步减小; 相比之下, 隐私情况下的学习过程不需要将学习率降低到一个非常小的值, 因为差分隐私训练会以隐私消耗不断增大的代价持续优化, 却未必真正达到模型收敛。因此, 以相对较大的学习率开始, 然后在一定周期内线性衰减到较小的值, 并在之后保持恒定, 性能会更好。

实验证明, 该策略改善了收敛稳定性, 最终在 $\epsilon = 9.76$ 时取得了 73.15 的 Final score, 明显优于固定噪声或低学习率配置。

(4) 隐私保护下的最终泛化性能结果如表 7 所示。最优隐私模型在 ODIR 域内双目指标上的 Off-site 和 On-site Final score 分别为 68.96 和 68.42, 相较无隐私版本下降约 10 个百分点, 但已接近 Li et al.[46] 报告的 ODIR 官方基线结果, 并在 Off-site 上略优于该基线 (68.00 vs. 68.96), 说明在中等隐私预算下, 所提方法能够在保持隐私保护的同时达到与公开基准接近的性能水平, 充分体现了自适应高斯差分隐私机制的有效性。

表 7: 隐私保护下的泛化性能对比。表中报告 ODIR 域内双目 Final score, 其中 Ours (privacy) 采用的是表 6 中选取的最优隐私检查点。在中等隐私预算下, 所提方法在 Off-site 上略优于 Li et al. [46] 报告的官方基线, 并在 On-site 上保持接近性能。

Model	Off-site	On-site
Li et al. [46]	68.00	68.80
Ours (privacy)	68.96	68.42

5 结论与讨论

本文提出了一种面向多标签眼科疾病识别的可解释与隐私保护单域泛化框架, 针对临床多疾病共存、多机构数据难以联合训练且跨机构部署存在域偏移、以及隐私泄露风险等问题, 构建了一种统一解决框架。核心贡献包括: (1) 自适应标签-特征关联性构建模块 (ARC), 利用 Transformer 自注意力机制和交叉注意力机制捕捉标签-标签关联性与标签-特征关联性, 并通过注意力一致性损失对齐双分支输出, 有助于减少多标签识别中的误检与漏检; (2) 双分支引导域不变特征提取模块 (DFE), 通过风格增强模拟潜在域偏移、CAM 提供疾病区域先验引导, 并结合空间/通道注意力与 mask 过滤提取域不变特征, 在提升未知域泛化性能的同时增强模型可解释性; (3) 自适应高斯差分隐私机制 (AdaGDP), 通过动态衰减噪声强度, 在中等隐私预算 ($\epsilon \approx 10$) 下控制性能损失, 实现隐私保护与模型性能的平衡。系统性的实验验证了所提方法的有效性。尽管取得一定进展, 本框架仍存在局限: 类别不平衡可能影响少数类疾病识别的稳定性, 未来可结合重采样或损失加权进一步缓解; 当前跨域泛化主要基于共有标签空间展开, 未来可探索开放类别和更复杂分布外场景下的泛化能力。

6 参考文献

1. Zhang W, Zhao X, Chen Y, et al. DeepUWF: an automated ultra-wide-field fundus screening system via deep learning[J]. IEEE Journal of Biomedical and Health Informatics, 2020, 25(8): 2988-2996.
2. Mujeeb Rahman K K, Nasor M, Imran A. Automatic screening of diabetic retinopathy using fundus images and machine learning algorithms[J]. Diagnostics, 2022, 12(9): 2262.
3. Lim G, Elangovan K, Jin L. Vision language models in ophthalmology[J]. Current Opinion in Ophthalmology, 2024, 35(6): 487-493.
4. Urooj B, Fayaz M, Ali S, et al. Large language models in medical image analysis: a systematic survey and future directions[J]. Bioengineering, 2025, 12(8): 818.

5. Kumar V, Singh R S, Rambabu M, et al. Deep learning for hyperspectral image classification: A survey[J]. *Computer Science Review*, 2024, 53: 100658.
6. Mo Y, Wu Y, Yang X, et al. Review the state-of-the-art technologies of semantic segmentation based on deep learning[J]. *Neurocomputing*, 2022, 493: 626-646.
7. Qiu D, Cheng Y, Wang X. Medical image super-resolution reconstruction algorithms based on deep learning: A survey[J]. *Computer Methods and Programs in Biomedicine*, 2023, 238: 107590.
8. Hasan S M M, Uddin M P, Al Mamun M, et al. A machine learning framework for early-stage detection of autism spectrum disorders[J]. *IEEE Access*, 2022, 11: 15038-15057.
9. Al-Fahdawi S, Al-Waisy A S, Zeebaree D Q, et al. Fundus-deepnet: Multi-label deep learning classification system for enhanced detection of multiple ocular diseases through data fusion of fundus images[J]. *Information Fusion*, 2024, 102: 102059.
10. Chen Z M, Wei X S, Wang P, et al. Multi-label image recognition with graph convolutional networks[C]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019: 5177-5186.
11. Liu S, Yin S, Qu L, et al. Reducing domain gap in frequency and spatial domain for cross-modality domain adaptation on medical image segmentation[C]//*Proceedings of the AAAI conference on artificial intelligence*. 2023, 37(2): 1719-1727.
12. Yang C, Guo X, Chen Z, et al. Source free domain adaptation for medical image segmentation with fourier style mining[J]. *Medical Image Analysis*, 2022, 79: 102457.
13. Bertino E, Ooi B C, Yang Y, et al. Privacy and ownership preserving of outsourced medical data[C]//*21st International Conference on Data Engineering (ICDE'05)*. IEEE, 2005: 521-532.
14. Wang Y, Xie Y, Fan L, et al. STMG: Swin transformer for multi-label image recognition with graph convolution network[J]. *Neural Computing and Applications*, 2022, 34(12): 10051-10063.
15. Zhang M L, Li Y K, Liu X Y, et al. Binary relevance for multi-label learning: an overview[J]. *Frontiers of Computer Science*, 2018, 12(2): 191-202.

16. Ridnik T, Ben-Baruch E, Zamir N, et al. Asymmetric loss for multi-label classification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 82-91.
17. Liu S, Zhang L, Yang X, et al. Query2label: A simple transformer way to multi-label classification[J]. arXiv preprint arXiv:2107.10834, 2021.
18. Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88(2): 303-338.
19. Cheng Y, Ma M, Li X, et al. Multi-label classification of fundus images based on graph convolutional network[J]. BMC Medical Informatics and Decision Making, 2021, 21(Suppl 2): 82.
20. He J, Li C, Ye J, et al. Multi-label ocular disease classification with a dense correlation deep neural network[J]. Biomedical Signal Processing and Control, 2021, 63: 102167.
21. Bhati A, Gour N, Khanna P, et al. Discriminative kernel convolution network for multi-label ophthalmic disease detection on imbalanced fundus image dataset[J]. Computers in Biology and Medicine, 2023, 153: 106519.
22. Guan H, Liu M. Domain adaptation for medical image analysis: a survey[J]. IEEE Transactions on Biomedical Engineering, 2021, 69(3): 1173-1185.
23. Tzeng E, Hoffman J, Zhang N, et al. Deep domain confusion: Maximizing for domain invariance[J]. arXiv preprint arXiv:1412.3474, 2014.
24. Sun B, Feng J, Saenko K. Return of frustratingly easy domain adaptation[C]//Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1).
25. Ganin Y, Ustinova E, Ajakan H, et al. Domain-adversarial training of neural networks[J]. Journal of machine learning research, 2016, 17(59): 1-35.
26. Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
27. Wang R, Wu Z, Weng Z, et al. Cross-domain contrastive learning for unsupervised domain adaptation[J]. IEEE Transactions on Multimedia, 2022, 25: 1665-1673.
28. Zhou K, Liu Z, Qiao Y, et al. Domain generalization: A survey[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(4): 4396-4415.

29. Zhou K, Yang Y, Qiao Y, et al. Domain generalization with mixstyle[J]. arXiv preprint arXiv:2104.02008, 2021.
30. Gulrajani I, Lopez-Paz D. In search of lost domain generalization[J]. arXiv preprint arXiv:2007.01434, 2020.
31. Xu Q, Zhang R, Zhang Y, et al. A fourier-based framework for domain generalization[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14383-14392.
32. Huang Z, Wang H, Xing E P, et al. Self-challenging improves cross-domain generalization[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 124-140.
33. Khoee A G, Yu Y, Feldt R. Domain generalization through meta-learning: a survey[J]. Artificial Intelligence Review, 2024, 57(10): 285.
34. Ouyang C, Chen C, Li S, et al. Causality-inspired single-source domain generalization for medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2022, 42(4): 1095-1106.
35. Yadav N, Pandey S, Gupta A, et al. Data privacy in healthcare: in the era of artificial intelligence[J]. Indian Dermatology Online Journal, 2023, 14(6): 788-792.
36. Aledhari M, Razzak R, Parizi R M, et al. Federated learning: A survey on enabling technologies, protocols, and applications[J]. IEEE Access, 2020, 8: 140699-140725.
37. Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.
38. Martins P, Sousa L, Mariano A. A survey on fully homomorphic encryption: An engineering perspective[J]. ACM Computing Surveys (CSUR), 2017, 50(6): 1-33.
39. Dutil F, See A, Di Jorio L, et al. Application of homomorphic encryption in medical imaging[J]. arXiv preprint arXiv:2110.07768, 2021.
40. Zhao C, Zhao S, Zhao M, et al. Secure multi-party computation: theory, practice and applications[J]. Information Sciences, 2019, 476: 357-372.
41. Sabt M, Achemlal M, Bouabdallah A. Trusted execution environment: What it is, and what it is not[C]//2015 IEEE Trustcom/BigDataSE/IsPa. IEEE, 2015, 1: 57-64.

42. Bu Z, Dong J, Long Q, et al. Deep learning with gaussian differential privacy[J]. Harvard data science review, 2020, 2020(23): 10.1162/99608f92.cfc5dd25.
43. Dong J, Roth A, Su W J. Gaussian differential privacy[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2022, 84(1): 3-37.
44. Bagdasaryan E, Poursaeed O, Shmatikov V. Differential privacy has disparate impact on model accuracy[J]. Advances in neural information processing systems, 2019, 32.
45. Dwork C, McSherry F, Nissim K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of cryptography conference. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006: 265-284.
46. Li N, Li T, Hu C, et al. A benchmark of ocular disease intelligent recognition: One shot for multi-disease detection[C]//International symposium on benchmarking, measuring and optimization. Cham: Springer International Publishing, 2020: 177-193.
47. Pachade S, Porwal P, Thulkar D, et al. Retinal fundus multi-disease image dataset (rfmid): A dataset for multi-disease detection research[J]. Data, 2021, 6(2): 14.
48. Sharmin S, Rashid M R, Khatun T, et al. A dataset of color fundus images for the detection and classification of eye diseases[J]. Data in Brief, 2024, 57: 110979.
49. Gour N, Khanna P. Multi-class multi-label ophthalmological disease detection using transfer learning based convolutional neural network[J]. Biomedical signal processing and control, 2021, 66: 102329.
50. Ou X, Gao L, Quan X, et al. BFENet: A two-stream interaction CNN method for multi-label ophthalmic diseases classification with bilateral fundus images[J]. Computer Methods and Programs in Biomedicine, 2022, 219: 106739.